

Vega Flow 最优做市：HJB 方程推导与求解

基于 Nutz, Webster, Zhao (2025) 的扩展

CRB Vega Desk 研究

June 22, 2026

Contents

1	问题设置与模型修改	2
1.1	原始 Delta 问题回顾	2
1.2	Vega 问题的两项核心修改	2
1.3	Price Impact 修改：专用函数替代 OW 假设	2
2	Vega 问题的 LQ 代价函数	3
2.1	完整代价函数	3
2.2	LQ 结构保持性	3
3	HJB 方程与 Riccati ODE 系统	3
3.1	值函数拟设	3
3.2	HJB 方程	3
3.3	修改后的 Riccati ODE 系统	4
3.4	与原始论文的对比	4
3.5	终端条件推导	4
3.6	极限情形验证	4
4	数值求解框架	5
4.1	ODE 求解策略	5
4.2	Price Impact 函数的集成	5
4.3	数值求解伪代码	5
5	参数 Calibration	6
5.1	需 Calibrate 的参数	6
5.2	Vega Flow OU 参数 MLE	6
5.3	有效 Impact 系数 Calibration	7
6	两个核心实验	7
6.1	实验一：Calibrated Flow vs 真实 Vega Flow	7
6.2	实验二：最优策略 q^* vs 真实市场策略	7
7	总结	8

1 问题设置与模型修改

1.1 原始 Delta 问题回顾

Nutz, Webster, Zhao (2025) 研究 Delta 仓位的最优解仓问题。状态变量为：

$$\begin{aligned} dX_t &= q_t dt - dZ_t, & X_0 &= x & (\text{库存}) \\ dY_t^c &= (-\beta_t Y_t^c + \lambda_t q_t) dt & & & (\text{价格冲击}) \\ dZ_t &= -\theta_t Z_t dt + \sigma_t dW_t & & & (\text{OU 订单流}) \end{aligned}$$

代价函数（命题 2.4, 式 2.15）：

$$C = \frac{1}{2} \mathbb{E} \int_0^T \left[\frac{2\beta_t + \dot{\gamma}_t}{\lambda_t} (Y_t^c)^2 + \varepsilon_t q_t^2 \right] dt + \frac{1}{\lambda_T} (\lambda_T X_T - Y_T^c)^2 + \text{const} \quad (1)$$

终端约束： $X_T = 0$ （硬约束，通过收盘拍卖的 J_T 实现）。

1.2 Vega 问题的两项核心修改

模型修改 1.1: 两项修改

Vega flow 问题与 Delta 问题有两处本质不同：

1. **Running cost (Gamma/Theta 风险)**: 持有 Vega 仓位 X_t^V 的同时, Delta 对冲产生 Gamma/Theta 的 P&L 风险。增加运行代价：

$$\phi_t (X_t^V)^2 \quad (2)$$

其中 $\phi_t \geq 0$ 为 Gamma-Theta 风险系数（与到期时间、隐含波动率等有关）。

2. **软终端约束**: Vega 不强制收盘清零，而是对隔夜剩余仓位施加软惩罚：

$$\psi (X_T^V)^2, \quad \psi \geq 0 \quad (3)$$

其中 ψ 由隔夜 vega 风险限额校准（ $\psi \rightarrow \infty$ 退化为硬约束）。

1.3 Price Impact 修改：专用函数替代 OW 假设

原始论文假设 price impact 服从广义 OW 模型（bps 单位）：

$$dY_t = -\beta_t Y_t dt + \lambda_t dQ_t$$

在 Vega 问题中，price impact 以 **vol points（波动率点数）** 计量，且由公司专用函数 $\Lambda(\cdot)$ 直接计算：

$$\text{Vol Impact} = \Lambda(q_t, \text{Vega}_t, \text{市场状态}_t) \quad (4)$$

该函数的输出直接替代 OW 模型中的 $\lambda_t q_t$ 项。在线性化/一阶近似下，仍可写成 $\Lambda(q_t) \approx \lambda_t^V q_t$ 的形式，其中 λ_t^V 为有效 vega impact 系数，由历史数据 calibrate 得到。

关键含义：HJB 方程的结构不变，但 λ_t 现在是 vega-space 中的有效参数，由 $\Lambda(\cdot)$ 函数在每次执行前实时计算。

2 Vega 问题的 LQ 代价函数

2.1 完整代价函数

将两项修改加入后, Vega 问题的代价函数为:

$$C^V = \frac{1}{2} \mathbb{E} \int_0^T \left[\frac{2\beta_t + \dot{\gamma}_t}{\lambda_t^V} (Y_t^{c,V})^2 + \varepsilon_t^V q_t^2 + 2\phi_t (X_t^V)^2 \right] dt + \psi (X_T^V)^2 \quad (5)$$

与原始问题对比:

	Delta 问题	Vega 问题
Running cost	$\frac{2\beta+\dot{\gamma}}{\lambda}(Y^c)^2 + \varepsilon q^2$	同上 $+2\phi_t(X^V)^2$
终端代价	$\frac{1}{\lambda_T}(\lambda_T X_T - Y_T^c)^2$	$\psi(X_T^V)^2$
Price impact	λ_t (OW 模型假设)	λ_t^V (由专用函数 $\Lambda(\cdot)$ 计算)
约束	$X_T = 0$ (硬约束)	无硬约束, 软惩罚

2.2 LQ 结构保持性

命题 1. 代价函数 (5) 保持 LQ 结构: 状态方程线性, 代价函数关于 $(X^V, Y^{c,V}, Z^V, q)$ 是二次型。因此值函数仍具有二次型形式, Riccati ODE 系统仍有解析解。

证明思路: 增加 $\phi_t(X_t^V)^2$ 等价于论文 Remark 2.11 中的 running inventory cost (令 $\alpha_t = \phi_t$); 软终端约束 $\psi(X_T^V)^2$ 改变终端条件但不破坏 LQ 性。

3 HJB 方程与 Riccati ODE 系统

3.1 值函数拟设

设 Vega 值函数仍为二次型 (论文命题 2.6 的直接推广):

$$v^V(t, x, y, z) = \frac{1}{2} A_t x^2 + B_t xy + \frac{1}{2} C_t y^2 + D_t xz + E_t yz + \frac{1}{2} F_t z^2 + K_t \quad (6)$$

3.2 HJB 方程

HJB 方程 (对 $t \in [0, T)$):

$$\partial_t v + \sup_q \left[-(\partial_x v + \lambda_t^V \partial_y v) q - \frac{\varepsilon_t^V}{2} q^2 \right] - \beta_t y \partial_y v - \theta_t z \partial_z v - \frac{\sigma_t^2}{2} \partial_{zz} v - \frac{2\beta_t + \dot{\gamma}_t}{\lambda_t^V} \frac{y^2}{2} - \phi_t x^2 = 0 \quad (7)$$

最优控制:

$$q_t^* = -\frac{1}{\varepsilon_t^V} (\partial_x v + \lambda_t^V \partial_y v) = f_t x + g_t y + h_t z \quad (8)$$

其中反馈系数 (类比原始论文式 2.19):

$$f_t = -(\varepsilon_t^V)^{-1} (A_t + \lambda_t^V B_t) \quad (9)$$

$$g_t = -(\varepsilon_t^V)^{-1} (B_t + \lambda_t^V C_t) \quad (10)$$

$$h_t = -(\varepsilon_t^V)^{-1} (D_t + \lambda_t^V E_t) \quad (11)$$

3.3 修改后的 Riccati ODE 系统

将值函数 (6) 代入 HJB, 比较各项系数, 得到:

Vega Riccati ODE 系统

$$\dot{A}_t = (\varepsilon_t^V)^{-1}(A_t + \lambda_t^V B_t)^2 - 2\phi_t, \quad A_T = \psi \quad (12)$$

$$\dot{B}_t = (\varepsilon_t^V)^{-1}(A_t + \lambda_t^V B_t)(B_t + \lambda_t^V C_t) + \beta_t B_t, \quad B_T = 0 \quad (13)$$

$$\dot{C}_t = (\varepsilon_t^V)^{-1}(B_t + \lambda_t^V C_t)^2 + 2\beta_t C_t - \frac{1}{\lambda_t^V}(2\beta_t + \dot{\gamma}_t), \quad C_T = \frac{1}{\lambda_T^V} \cdot \frac{\psi}{\psi \lambda_T^V + 1} \quad (14)$$

$$\dot{D}_t = (\varepsilon_t^V)^{-1}(A_t + \lambda_t^V B_t)(D_t + \lambda_t^V E_t) - \theta_t(A_t - D_t), \quad D_T = 0 \quad (15)$$

$$\dot{E}_t = (\varepsilon_t^V)^{-1}(B_t + \lambda_t^V C_t)(D_t + \lambda_t^V E_t) - \theta_t(B_t - E_t) + \beta_t E_t, \quad E_T = 0 \quad (16)$$

$$\dot{F}_t = (\varepsilon_t^V)^{-1}(D_t + \lambda_t^V E_t)^2 - 2\theta_t(D_t - F_t), \quad F_T = 0 \quad (17)$$

$$\dot{K}_t = -\frac{\sigma_t^2}{2}(A_t - 2D_t + F_t), \quad K_T = 0 \quad (18)$$

3.4 与原始论文的对比

ODE	Delta 问题 (原始)	Vega 问题 (修改)
$\dot{A}_t$	$\varepsilon^{-1}(A + \lambda B)^2$	$\varepsilon^{-1}(A + \lambda B)^2 - 2\phi_t$
A_T	λ_T	ψ
B_T	-1	0
C_T	λ_T^{-1}	$\frac{1}{\lambda_T^V} \cdot \frac{\psi}{\psi \lambda_T^V + 1}$
D_T, E_T, F_T, K_T	0	0 (不变)

3.5 终端条件推导

软终端代价 $\psi(X_T^V)^2$ 对应值函数终端条件:

$$v^V(T, x, y, z) = \psi x^2$$

因此 $A_T = \psi$, $B_T = C_T^{\text{soft}} = D_T = \dots = 0$ 。

但由于终端 impact 状态 Y_T^c 与 X_T^V 的耦合, 精确的 C_T 需通过匹配终端代价与值函数的 y^2 系数得到:

$$C_T = \frac{\psi/(\lambda_T^V)^2}{\psi/\lambda_T^V + 1} = \frac{\psi}{\lambda_T^V(\psi \lambda_T^V + 1)}$$

(当 $\psi \rightarrow \infty$: $C_T \rightarrow 1/\lambda_T^V$, 恢复原始论文终端条件; 当 $\psi = 0$: $C_T = 0$, 无终端惩罚。)

3.6 极限情形验证

- $\psi \rightarrow \infty, \phi_t = 0$: 恢复原始论文的 Delta 问题 ODE (将 λ^V 替换为 λ)。
- $\psi = 0, \phi_t = 0$: 自由终端, desk 无需在收盘前降低 vega 仓位。

- $\phi_t > 0$: 加速 vega 降仓 (因持仓的 γ/θ 成本使 A_t 增长更慢, 进而加大 f_t 的绝对值, 即 q^* 对 x 的敏感性增强)。

4 数值求解框架

4.1 ODE 求解策略

系统 (12)–(18) 是终值 ODE, 需从 T 倒推到 0。

步骤:

1. 用 `scipy.integrate.solve_ivp` (RK45), 以 $s = T - t$ (顺时间方向积分) 求解。
2. (A, B, C) 子系统自治, 先独立求解 (只依赖 $\varepsilon_t^V, \beta_t, \lambda_t^V$)。
3. (D, E, F, K) 子系统在已知 (A, B, C) 后线性, 独立求解。
4. 在有 ϕ_t 的情形下, A 方程的 $-2\phi_t$ 项使 A_t 增长更缓慢甚至减小, 需检查 $A_t \geq 0$ (凸性条件) 是否维持。

4.2 Price Impact 函数的集成

由于 $\Lambda(\cdot)$ 是专用函数 (非 OW 解析形式), 数值积分时在每个时间步:

1. 给定当前 Vega 执行速度 q_t (由反馈策略给出);
2. 调用 $\Lambda(q_t, \text{状态})$ 得到实际 vol impact;
3. 反解等效 $\lambda_t^V = \Lambda(q_t, \cdot)/q_t$ (线性化);
4. 在 ODE 系统中使用该 λ_t^V 。

若 Λ 非线性, 则每日重新 calibrate λ_t^V (pre-market), intraday 使用固定的当日系数——这与论文框架完全兼容。

4.3 数值求解伪代码

```
def solve_vega_riccati(params):
    # params: eps_V, beta, lambda_V, theta, sigma, phi, psi, T, dt

    # 终端条件
    A_T = params.psi
    B_T = 0.0
    C_T = psi / (lambda_V_T * (psi * lambda_V_T + 1))
    D_T = E_T = F_T = K_T = 0.0

    # 倒推 ODE (s = T - t, 从 s=0 积分到 s=T)
    def ode_rhs(s, state):
        t = T - s
        A, B, C, D, E, F, K = state
        lam = lambda_V(t); eps = eps_V(t)
        bt = beta(t); th = theta(t); sig = sigma(t)
```

```

ph = phi(t)

AB = A + lam * B; BC = B + lam * C; DE = D + lam * E

dA = -(eps**-1 * AB**2 - 2*ph)
dB = -(eps**-1 * AB * BC + bt * B)
dC = -(eps**-1 * BC**2 + 2*bt*C - (2*bt+dgamma(t))/lam)
dD = -(eps**-1 * AB * DE - th*(A - D))
dE = -(eps**-1 * BC * DE - th*(B - E) + bt*E)
dF = -(eps**-1 * DE**2 - 2*th*(D - F))
dK = -(- sig**2/2 * (A - 2*D + F))
return [dA, dB, dC, dD, dE, dF, dK]

sol = solve_ivp(ode_rhs, [0, T], [A_T, B_T, C_T, ...])
return sol # 倒序即为 t [0, T] 的解

```

5 参数 Calibration

5.1 需 Calibrate 的参数

参数	含义	Calibration 方法
θ	Vega flow OU 均值回归速度	MLE on historical vega flow
σ	Vega flow 波动率	MLE on historical vega flow
ε_t^V	Spread/execution cost	From transaction cost model
β_t	Vol impact 衰减速度	From $\Lambda(\cdot)$ 函数特性或历史拟合
λ_t^V	有效 vol impact 系数	由 $\Lambda(\cdot)$ 线性化得到
ϕ_t	Gamma-Theta 风险系数	From options Greeks / risk model
ψ	隔夜软惩罚系数	从隔夜 vega 风险限额反推

5.2 Vega Flow OU 参数 MLE

观测序列 $\{Z_{t_i}\}$, 离散化 OU 过程:

$$Z_{t+\Delta} = Z_t e^{-\theta\Delta} + \varepsilon_t, \quad \varepsilon_t \sim \mathcal{N}\left(0, \frac{\sigma^2}{2\theta}(1 - e^{-2\theta\Delta})\right)$$

对数似然 (精确离散化):

$$\ell(\theta, \sigma^2) = -\frac{n}{2} \ln(2\pi v^2) - \frac{1}{2v^2} \sum_{i=1}^n (Z_{t_{i+1}} - Z_{t_i} e^{-\theta\Delta})^2 \quad (19)$$

$$v^2 = \frac{\sigma^2}{2\theta}(1 - e^{-2\theta\Delta}) \quad (20)$$

同时 calibrate: 均值回归水平 μ (若 flow 非零均值):

$$Z_{t+\Delta} = \mu(1 - e^{-\theta\Delta}) + Z_t e^{-\theta\Delta} + \varepsilon_t$$

5.3 有效 Impact 系数 Calibration

由历史执行数据:

$$\lambda_t^V \approx \frac{\Delta \text{Vol}_t}{\Delta Q_t^V} \approx \frac{\text{Vol Impact in vol points}}{\text{Vega executed (in \$vega)}}$$

实操: 对历史 $(q_t, \text{vol impact})$ 做 OLS 或 robust regression, 控制 Vega flow 的 Z_t 水平, 得到 $\hat{\lambda}_t^V$ 。

6 两个核心实验

6.1 实验一: Calibrated Flow vs 真实 Vega Flow

目标: 验证 calibrate 后的 OU 参数能否 generate 出与真实 vega flow 统计特征一致的路径。

评估指标:

- 自相关函数 (ACF) 比较 (理论 $\text{ACF} = e^{-\theta k \Delta}$)
- 一阶/二阶矩比较: 均值、方差
- Q-Q 图 (正态性)
- KS 检验: 模拟分布 vs 历史分布
- 动量指标 $|Z_T|/\text{TV}(Z)$ (论文 Figure 7 的实时 KPI)

实验设计:

1. 从历史数据中分段 (按日) 提取 vega flow 序列 $\{Z_{t_i}^{\text{real}}\}$;
2. 用 MLE 得到 $(\hat{\theta}, \hat{\sigma}, \hat{\mu})$;
3. 用 calibrated 参数 Monte Carlo 模拟 $N = 1000$ 条路径;
4. 比较统计特征。

6.2 实验二: 最优策略 q^* vs 真实市场策略

目标: 在相同 vega flow 实现路径下, 比较 (A) 理论最优策略 $q_t^* = f_t X_t^V + g_t Y_t^{c,V} + h_t Z_t$ 与 (B) 历史实际仓位变化策略的总成本。

成本计算:

- 理论策略成本: 用 q^* 对真实 Z_t 路径前向模拟, 计算 (5) 的实现值;
- 历史策略成本:

$$C^{\text{hist}} = \frac{1}{2} \int_0^T \left[\frac{2\beta_t + \dot{\gamma}_t}{\lambda_t^V} (Y_t^{c,\text{hist}})^2 + \varepsilon_t^V (q_t^{\text{hist}})^2 + 2\phi_t (X_t^{V,\text{hist}})^2 \right] dt + \psi (X_T^{V,\text{hist}})^2$$

- 成本比较指标:

$$\text{Cost Ratio} = \frac{C^{\text{opt}}}{C^{\text{hist}}}, \quad \text{Cost Saving (bps)} = C^{\text{hist}} - C^{\text{opt}}$$

统计检验:

- 配对 t 检验: $H_0: C^{\text{opt}} = C^{\text{hist}}$ (按日)
- 分层分析: 按 $|Z_T|/\text{TV}(Z)$ 高/中/低分组
- Bootstrap 置信区间

7 总结

关键结论 7.1: Vega 问题解的结构

1. **HJB 不变:** 结构与原始论文相同, 最优控制仍为 $q^* = f_t x + g_t y + h_t z$ 。
2. **ODE 修改极小:** 仅 A_t 方程多了 $-2\phi_t$ 项; 终端条件 $A_T = \psi, B_T = 0$ 。
3. **LQ 解析性保持:** ODE 可数值求解 (毫秒级), Monte Carlo 只用于盘前成本报价。
4. **$\Lambda(\cdot)$ 函数集成:** 通过每日 pre-market calibrate λ_t^V 自然进入框架。
5. **极限验证:** $\psi \rightarrow \infty, \phi = 0$ 精确恢复原始 Delta 问题 (Prop 2.7)。